案例1: 腾讯招聘

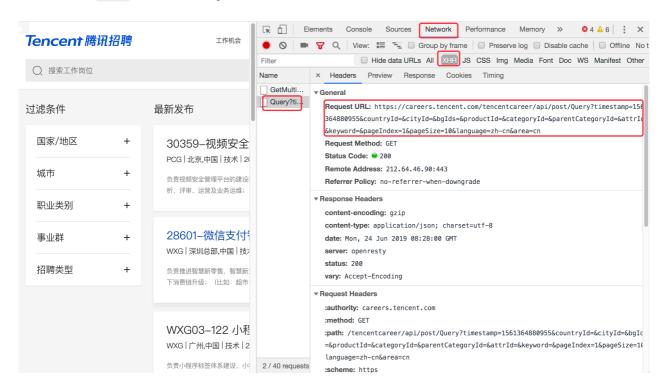
1> 页面分析

抓取目标腾讯招聘首页

通过自行探索发现:下一页url为空

猜测:网页是否使用ajax发送数据?

还是<u>原来的页面</u>,打开谷歌浏览器开发者工具(按F12),选择 Network 菜单项,指定 XHR 即只查看ajax请求数据:



● 去掉多余参数,可得请求url为

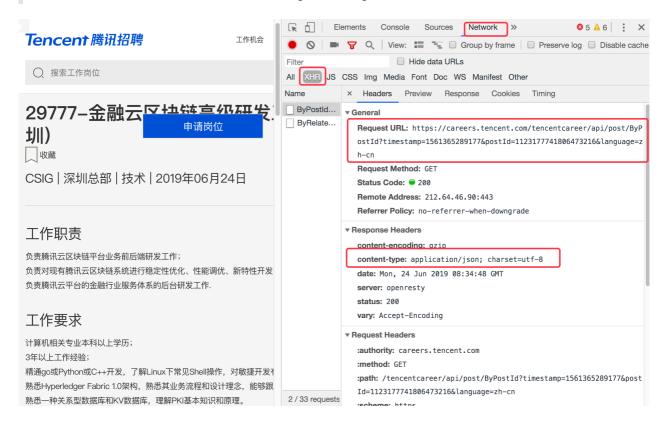
https://careers.tencent.com/tencentcareer/api/post/Query?
pageIndex=1&pageSize=10

• 再次请求,查看json数据结构

```
Count: 4156.
              PostId: "1143072200434126848",
             RecruitPostName: "22989-数据分析师(BI)",
             CountryName: "中国",
             LocationName: "深圳",
             BGName: "CSTG"
             Responsibility: 1. 建立腾讯云业务数据分析体系,为业务管理决策与运营提供高质量数据服务。 2. 负责对应业务的数据梳理与数据接入,并设计数仓模型。 3. 负责对应业务的
             数据监控,分析业务指标变化趋势,并做出解释。 4.结合各行业、业务运营现状与专项需求,提出优化改进措施并落地。 5.建立腾讯云数据中台。
             LastUpdateTime: "2019年06月24日",
             PostURL: "http://careers.tencent.com/jobdesc.html?postId=0",
SourceID: 1,
             IsCollect: false,
IsValid: false
             PostId: "1123177741806473216",
             RecruitPostId: 49097,
RecruitPostName: "29777-金融云区块链高级研发工程师(深圳)",
             CountryName: "中国",
             LocationName: "深圳总部",
BGName: "CSIG",
ProductName: "",
             CategoryName: "技术",
             Responsibility: "负责腾讯云区块链平台业务前后端研发工作; 负责对现有腾讯云区块链系统进行稳定性优化、性能调优、新特性开发等工作;负责腾讯云平台的金融行业服务体系的
             LastUpdateTime: "2019年06月24日",
             PostURL: "http://careers.tencent.com/jobdesc.html?postId=1123177741806473216", SourceID: 1,
             IsCollect: false,
             IsValid: false
Data.Posts[0].Re
```

详情页

探索发现详情页数据也是使用ajax发送json数据



2> 新建项目及数据需求

• 新建爬虫项目

```
$ scrapy startproject Tencent
```

● 由页面分析可得能获取到的有效字段,编辑item.py文件

```
class TencentItem(scrapy.Item):
    # define the fields for your item here like:
    name = scrapy.Field()  # 岗位名称
    post_id = scrapy.Field()  # 岗位编号
    publish_date = scrapy.Field()  # 发布时间
    category = scrapy.Field()  # 工作分类
    duty = scrapy.Field()  # 岗位职责
    country = scrapy.Field()  # 国家
    location = scrapy.Field()  # 工作地点
    require = scrapy.Field()  # 工作要求
```

3> 新建爬虫并实现数据解析

• 新建爬虫

```
$ cd Tencent
$ scrapy genspider tencent 'tencent.com'
```

• 修改allowed domains、start urls

• 列表页数据解析

```
def parse(self, response):
    data_json = json.loads(response.text)
    for data in data_json["Data"]["Posts"]:
        item = TencentItem()
        item["name"] = data["RecruitPostName"]
        item["post_id"] = data["PostId"]
        item["publish_date"] = data["LastUpdateTime"]
        item["category"] = data["CategoryName"]
        item["duty"] = data["Responsibility"]
        item["country"] = data["CountryName"]
        item["location"] = data["LocationName"]
```

• 发起详情页请求

• 详情页数据解析

```
def parse_detail(self, response):
    """详情页解析"""
    item = response.meta["item"]
    data_json = json.loads(response.text)
    item["require"] = data_json["Data"]["Requirement"]
    yield item
```

4>数据持久化及配置文件

• 把数据保存到mongoDB, 编辑piplines.py

```
from datetime import datetime
from pymongo import MongoClient
from scrapy.conf import settings
class TencentPipeline(object):
   def __init__(self):
       # 读取配置参数
       host = settings['MONGO_HOST']
       port = settings['MONGO PORT']
       db_name = settings['MONGO_DBNAME']
       col_name = settings['MONGO_COLNAME']
       now_str = datetime.now().strftime("%m_%d_%H %M")
       col name += " " + now str
       # 连接mongodb数据库
       self.handle = MongoClient(host, port)
       # 选择数据库
       self.db = self.handle[db_name]
       # 选择集合
       self.col = self.db[col_name]
   def process_item(self, item, spider):
       # 1. 使用post id做主键
       data = dict(item) # 将item实例转化为字典
       # 2. 查询库中数据是否已存在,不存在才存库
       res = self.col.find_one({"_id": data["post_id"]})
       if not res:
           data[" id"] = data.pop("post id")
           self.col.insert(data) # 写入数据库
       return item
```

```
def close_spider(self, spider):
# 关闭数据库链接
self.handle.close()
```

• 配置文件settings.py

```
LOG_LEVEL = "WARNING"

MONGO_HOST = '127.0.0.1'
MONGO_PORT = 27017
MONGO_DBNAME = 'spider'
MONGO_COLNAME = 'tencent'

USER_AGENT = 'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_12_6)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/68.0.3440.106
Safari/537.36'
......

ITEM_PIPELINES = {
    'Tencent.pipelines.TencentPipeline': 300,
}
```